




## 언어모델(Language Model)

## ● 언어모델 개요

### 언어모델(Language Model)

문맥을 고려하여 문장(Sentence) 기반으로 임베딩을 수행

ELMo, GPT, BERT, GPT2 등의 임베딩 방법



<출처: 워드 임베딩. <https://towardsdatascience.com>. 20. 9>



## ● 언어모델의 성장


트랜스포머 등장 이후 2018년 ~ 2020년 기간 동안 트랜스포머를 이용한  
다양한 언어모델의 등장 및 인공지능 언어모델의 폭발적 성장

| 언어모델    | 발표시기      | 모델 발표 기관                                      |
|---------|-----------|-----------------------------------------------|
| ELMo    | 2018년 2월  | Allen AI와 Washington University               |
| GPT-1   | 2018년 5월  | Open AI                                       |
| BERT    | 2018년 10월 | Google                                        |
| GPT-2   | 2019년 2월  | Open AI                                       |
| KoBERT  | 2019년 6월  | ETRI                                          |
| XLNet   | 2019년 7월  | Carnegie Mellon University와 Google Brain      |
| RoBERTa | 2019년 7월  | Facebook AI Research                          |
| ALBERT  | 2019년 9월  | Google과 TTIC(Toyota Technological at Chicago) |
| T5      | 2019년 10월 | Google                                        |
| KoGPT-2 | 2020년 4월  | SKT와 AWS                                      |
| GPT-3   | 2020년 6월  | Open AI                                       |

# 인공지능 언어모델 개요



## ● 언어모델의 발전과정



## ● 언어모델의 분류



문장의 **학습 방향**에 따라  
순방향, 역방향, 양방향 언어모델로 분류



순방향 언어모델

OpenAI GPT 계열, ELMo

역방향 언어모델

ELMo

완전 양방향 언어모델

BERT 계열, XLNet

## ● 언어모델의 분류

OpenAI GPT는 순방향 언어모델로 NLG 위주  
Google BERT는 양방향 언어모델로 NLU 위주





## ● BERT

### BERT(Bidirectional Encoder Representations from Transformers)

2018년 10월 구글이 발표한 Pre-Trained 기반 딥러닝 언어모델

- 대형 코퍼스에서 비지도학습(Unsupervised Learning)으로 General-Purpose Language Understanding 모델을 구축(Pre-training)
- 지도학습(Supervised Learning)으로 Fine-Tuning해서 QA, STS 등의 Downstream NLP 태스크에 적용하는 Semi-Supervised Learning 모델



## ● BERT

트랜스포머로 구현되어 다양한 자연어 처리 분야에 활용



트랜스포머의 인코더만 사용, BERT Base는 12개의 트랜스포머 블록, Bert Large는 24개의 트랜스포머 블록을 사용


사전 훈련 데이터로 BooksCorpus 8억 단어,  
Wikipedia 25억 단어를 사용





## ● BERT

### ▬ BERT의 학습 절차





## ● BERT

### ▬ BERT의 학습 절차

Input  
Embeddings

- BERT는 트랜스포머와 달리 Positional Encoding을 사용하지 않고 Position Embeddings를 사용
- Input Embeddings

= Position Embeddings + Segment Embeddings + Token Embeddings



## ● BERT

### ▬ BERT의 학습 절차

|                     |             |          |           |          |            |             |          |             |            |             |             |
|---------------------|-------------|----------|-----------|----------|------------|-------------|----------|-------------|------------|-------------|-------------|
| Input               | [CLS]       | my       | dog       | is       | cute       | [SEP]       | he       | likes       | play       | ##ing       | [SEP]       |
| Token Embeddings    | $E_{[CLS]}$ | $E_{my}$ | $E_{dog}$ | $E_{is}$ | $E_{cute}$ | $E_{[SEP]}$ | $E_{he}$ | $E_{likes}$ | $E_{play}$ | $E_{##ing}$ | $E_{[SEP]}$ |
|                     | +           | +        | +         | +        | +          | +           | +        | +           | +          | +           | +           |
| Segment Embeddings  | $E_A$       | $E_A$    | $E_A$     | $E_A$    | $E_A$      | $E_A$       | $E_B$    | $E_B$       | $E_B$      | $E_B$       | $E_B$       |
|                     | +           | +        | +         | +        | +          | +           | +        | +           | +          | +           | +           |
| Position Embeddings | $E_0$       | $E_1$    | $E_2$     | $E_3$    | $E_4$      | $E_5$       | $E_6$    | $E_7$       | $E_8$      | $E_9$       | $E_{10}$    |

[SEP]

문장의 끝을 나타내는 식별자로 두 문장을 구분하는 역할

[CLS]

문장의 맨 앞에는 클래스를 뜻하는 **CLS**를 추가



## ● BERT

### ▬ BERT의 학습 절차

#### Pre-Training

- Pre-Training 단계에서 BERT는 언어의 특성을 잘 학습하기 위해 **MLM**(Masked Language Model)과 **NSP**(Next Sentence Prediction) 방식 사용



## ● BERT

### ■ BERT의 학습 절차

**MLM**(Masked Language Model)

≫ 문장의 다음 단어를 예측하는 것이 아니라 문장 내 랜덤한 단어를 마스킹하고 예측하도록 하는 방식

≫ Word2Vec의 CBOW 모델과 유사

↓  
CBOW는 Context 토큰을 Center 토큰이 되도록 학습하고 Weights를 벡터로 가짐

MLM은 마스킹된 토큰을 맞추도록 학습한 결과를 직접 벡터로 갖기 때문에 보다 직관적인 방식



## ● BERT

### ■ BERT의 학습 절차

#### MLM(Masked Language Model)

- ≫ 문장의 다음 단어를 예측하는 것이 아니라 문장 내 랜덤한 단어를 마스킹하고 예측하도록 하는 방식
- ≫ Word2Vec의 CBOW 모델과 유사

마스킹은 전체 단어의 15% 정도의 비율 사용

모든 토큰을 마스킹 하는게 아니라  
80% 정도의 토큰에 대해서만 <MASK>로 처리

10%는 Random한 단어

나머지 10%는 정상적인 단어를 그대로 사용



## ● BERT

### ■ BERT의 학습 절차

#### Attention Masking

≫ BERT는 Inference 단계에서 Zero Padding으로 입력된 토큰에 대해서는 항상 마스킹 처리

해당 토큰에 대해서는 Penalty를 부과하여 Attention score 계산


≫ 트랜스포머는 FFNN(Feed Forward Neural Network)에 ReLU Activation을 적용했지만 BERT는 GELU(Gaussian Error Linear Unit) Activation을 적용



## ● BERT

### ▬ BERT의 학습 절차

Attention Masking







## ● BERT

### ■ BERT의 학습 절차

#### NSP(Next Sentence Prediction)

- 주어진 두 문장에 대해 두 번째 문장이 코퍼스 내에서 첫 번째 문장 바로 다음에 오는지 여부를 예측
- **이 방식의 사용 이유:** BERT는 전이 학습으로 사용되고 QA와 NLI(Natural Language Inference) 등의 태스크에서는 MLM으로 학습하는 것은 충분하지 않았기 때문

두 문장이 실제로 연결된 문장인지의 여부를 예측하기 위해

- 50% 비율의 실제 연결된 문장
- 랜덤하게 추출된 연결되지 않은 문장 사용



## ● BERT

### ■ BERT의 학습 절차

#### NSP(Next Sentence Prediction)

- » 주어진 두 문장에 대해 두 번째 문장이 코퍼스 내에서 첫 번째 문장 바로 다음에 오는지 여부를 예측
- » 이 방식의 사용 이유: BERT는 전이 학습으로 사용되고 QA와 NLI(Natural Language Inference) 등의 태스크에서는 MLM으로 학습하는 것은 충분하지 않았기 때문
- » [CLS] 벡터의 Binary Classification 결과를 예측하도록 학습



## ● BERT


### ▬ BERT의 학습 절차

Transfer  
Learning

- 대량 코퍼스로 BERT 언어모델을 적용하고, BERT 언어모델 출력에 추가적인 모델을 추가하여 문제 해결을 위한 의도에 맞는 모델 생성

## ● BERT

### ▬ BERT의 학습 절차




## ● BERT

### ■ BERT의 학습 절차

#### 두 문장의 분류

- 두 문장을 입력 데이터로 사용하여 문장을 분류하는 TASK




## ● BERT

### ■ BERT의 학습 절차

한 문장의 분류

- 한 문장을 토큰화 하여 입력 데이터로 사용하여 분류




## ● BERT

### ■ BERT의 학습 절차

Question  
Answering

- Question과 Paragraph를 입력 데이터로 사용하여 Answer를 예측




## ● BERT

### ■ BERT의 학습 절차

개체명 인식  
(Named Entity Recognition)

- 한 문장을 입력 데이터로 사용하여 문장 내 토큰명 개체명 분류







## ● RoBERTa

### RoBERTa(A Robustly Optimized BERT)

BERT보다 성능을 한 단계 업그레이드한 버전

- 모델 크기를 크게 하여 성능을 높이기 위한 방법 적용
- **훈련 데이터의 양**(13GB→160GB), **학습 횟수**(125,000회→500,000회), **배치 크기**(256→8,192), **사전 크기**(32,000→50,000)
- BERT의 Next Sentence Prediction은 훈련에서 제외



## ● ALBERT

### ALBERT(A Lite BERT)

BERT보다 가벼운 모델

- 모델 매개변수 수를 줄여 같은 구조의 모델에서의 메모리 사용량을 줄이고 학습 속도는 개선
- 각 단어를 저차원의 임베딩 벡터로 표현
  - 이를 다시 모델 은닉층의 차원 수만큼 확장
- 트랜스포머 인코더 블록 간 매개변수를 공유



## ● ALBERT

### ALBERT(A Lite BERT)

- BERT(Large)에 비해 매개변수 수는 1/18

3억 3,400만개 → 1,800만개

- GLUE 성능을 일정 수준 유지하면서(85.2→82.4) 학습 속도를 1.7배 개선
- BERT의 Next Sentence Prediction 대신 두 문장의 연관 관계를 예측하는 문장 순서 예측(Sentence Order Prediction, SOP)을 통해 훈련 성능 개선



## ● T5

### T5

- 하나의 모델로 모든 문제를 해결할 수 있도록 모델의 크기를 대폭 확대
- GLUE와 SQuAD 등에 포함된 다양한 자연어 이해(NLU) 데이터 셋을 사전 훈련
- 정제 텍스트 데이터 700GB, 모델 매개변수는 110억개 규모

정제 텍스트 데이터는 RoBERTa의 4.4배 / 모델 매개변수는 32배

- 빈칸 하나의 예측값이 다른 빈칸 예측에 영향을 주지 않는 BERT의 한계를 극복하기 위해 Seq2Seq 구조의 Masked Language Model을 적용



T5는 SuperGLUE에서 인간과 비슷한 성능을 달성



## ● KoBERT

### KoBERT

- 엑소브레인 사업에서 한국어의 특성을 반영하여 개발한 BERT 언어모델

엑소브레인: 과학기술정보통신부와 IITP의 혁신성장동력 프로젝트로 추진 중인 사업

- ETRI 엑소브레인 연구진이 배포하는 한국어 최첨단 딥러닝 언어모델은 한국어분석·기계독해·문서분류 등 다양한 태스크에 활용 가능



5종의 한국어 처리 태스크에서 구글이 배포한 한국어 언어모델과 비교 평가한 결과, ETRI의 언어모델이 평균 4.5% 성능 우수

- 5종: 의미역 인식, 기계독해, 단락 순위화, 문장 유사도 추론, 문서 주제분류

## ● GPT 언어모델

### GPT(Generative Pre-training Transformers)

#### GPT

- OpenAI에서 발표(2018)
- **Transformer Decoder**로 구현
- 이전 단어를 입력으로 하여 다음 단어를 출력으로 하는 **단방향 언어모델**
- 자연어 생성(NLG)에서 우수한 성능을 보임

#### GPT 2

- 웹 페이지 크롤링을 통해 4500만개의 링크에서 Text **40GB**를 활용(소설 3만5천개)
- 모델 파라미터 수는 **15억개**  
(Bert-Large 3.4억개)
- 특정 Task에 맞게 Finetuning하지 않은 상태에서 기능을 측정 Zero-shot Learning

## ● 거대 언어모델(LLM)의 등장

### GPT3

- 웹 페이지 크롤링을 통해 수집한 4990억개 데이터셋 중에서 가중치 샘플링을 통해서 3000억(300B)개로 구성된 데이터셋으로 사전 학습(pre-training)
- 모델 파라미터 수는 1750억개



Fine-tuning 없이  
자연어 처리 벤치마크 테스트에서 최고의 성능 달성

OpenAI는 훈련된 모델 또는 전체 소스코드는 미공개



## ● 전이 학습의 개요

전이 학습(Transfer Learning)이란?


대규모 데이터 셋으로 사전에 학습이 완료된  
언어모델(Pre-trained Language Model)을 사용



사전 학습된 모델을 해결하고자하는 문제에 적합하도록  
**미세조정(Fine-tuning)**하여 학습시키는 기법




## ● 전이 학습의 개요




## Pre-Trained 모델의 Fine-Tuning 전략

- 전이 학습을 통해 새롭게 생성된 New Model에 대한 최적화된 Train 전략
- Train Entire Model, Frozen Partial, Train Classifier Only 전략이 존재




## ● Pre-Trained 모델의 Fine-Tuning 전략





## ● Pre-Trained 모델의 Fine-Tuning 전략






## ● Pre-Trained 모델의 Fine-Tuning 전략



## ● 전이 학습 전략의 선택

데이터 크기와 데이터 유사도에 따라 선택 필요



## ● 전이 학습 전략의 선택

