

BERT 모델을 활용한 Text Classification 모델 구현

BERT Binary Classification 모델 구현

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 준비

◆ 영화평 데이터 세트 업로드 및 Pandas를 이용한 데이터 로드

```
import pandas as pd

dataset = pd.read_table("/content/mnt/MyDrive/ratings_train.txt")

dataset.columns=['id', 'review', 'sentiment']
```

BERT 모델을 활용한 Text Classification 모델 구현

BERT Binary Classification 모델 구현

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 준비

◆ 영화평 데이터 세트 업로드 및 Pandas를 이용한 데이터 로드

```
dataset.head()
```

	id	review	sentiment
0	9976970	더빙이 실망스럽네요..	0
1	3819312	오버연기조차 가볍지 않구나	1
2	10265843	너무재밌었다. 그래서보는것을추천한다	0
3	9045019	솔직히 재미는 없다..평점 조정	0
4	6483659	배우의 익살스런 연기가 돋보였던 영화!	1

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 준비

◆ sklearn을 이용한 train(80%), test(20%) 데이터 세트 분리

- stratify 파라미터를 통한 층화 샘플링(Stratified Sampling)

```
from sklearn.model_selection import train_test_split

train_idx, test_idx, _, _ = train_test_split(dataset.index, dataset.sentiment,
                                             test_size=0.2, stratify=dataset.sentiment)

train_set = dataset.iloc[train_idx]
test_set = dataset.iloc[test_idx]
train_set.reset_index(drop=True, inplace=True)
```

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 준비

- ◆ train 데이터 세트를 이용하여 train(70%), validation(30%) 데이터 세트 분리
 - stratify 파라미터를 통한 층화 샘플링(Stratified Sampling)

```
train_idx, valid_idx, _, _ = train_test_split(train_set.index, train_set.sentiment,  
                                              test_size=0.3, stratify=train_set.sentiment)
```

```
valid_set = train_set.iloc[valid_idx]  
train_set = train_set.iloc[train_idx]
```

```
train_set.shape, valid_set.shape, test_set.shape
```

```
((84000, 3), (36000, 3), (30000, 3))
```

BERT 모델을 활용한 Text Classification 모델 구현

BERT Binary Classification 모델 구현

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 클래스 정의

`torch.utils.data.Dataset` 상속

`__init__()`, `__len__()`, `__getitem__()` 함수 재정의

`__init__()` Text/Label 설정, Tokenizer, 최대 Token 수 지정

`__len__()` 전체 데이터 세트의 개수 리턴

`__getitem__()` 특정 index에 해당하는 입력 Text ID, attention mask, label 리턴

BERT 모델을 활용한 Text Classification 모델 구현

BERT Binary Classification 모델 구현

+ 학습 및 평가 데이터 세트

◆ Pre-trained Tokenizer 다운로드

◆ Huggingface로부터 Pre-trained Tokenizer 다운로드

```
bert_model_name = 'kykim/bert-kor-base'
```

```
tokenizer = BertTokenizerFast.from_pretrained(bert_model_name)
```

Downloading: 100%  336k/336k [00:00<00:00, 364kB/s]

Downloading: 100%  80.0/80.0 [00:00<00:00, 1.87kB/s]

Downloading: 100%  725/725 [00:00<00:00, 13.9kB/s]

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 클래스 객체 생성

◆ Train 데이터 세트와 Validation 데이터 세트를 이용하여 객체 생성

```
train_set_dataset = BertDataset(  
    reviews      = train_set.review.tolist(),  
    sentiments   = train_set.sentiment.tolist(),  
    tokenizer     = tokenizer,  
)  
  
valid_set_dataset = BertDataset(  
    reviews      = valid_set.review.tolist(),  
    sentiments   = valid_set.sentiment.tolist(),  
    tokenizer     = tokenizer,  
)
```


BERT 모델을 활용한 Text Classification 모델 구현

BERT Binary Classification 모델 구현

+ Pre-trained 모델 다운로드 및 Fine-tuning 설정

◆◆ Pre-trained 모델 다운로드

- ◆ Huggingface로부터 한국어 학습 모델 중 하나인 'kykim/bert-kor-base' Pre-trained 모델 다운로드

```
from transformers import BertForSequenceClassification
```

```
model = BertForSequenceClassification.from_pretrained(bert_model_name)
```

Downloading: 100%  454M/454M [00:11<00:00, 36.7MB/s]

- ◆ [참고] 한국어 학습 모델 검색

- <https://huggingface.co/models> 에서 'kor' 검색

BERT 모델을 활용한 Text Classification 모델 구현

BERT Binary Classification 모델 구현

+ Pre-trained 모델 다운로드 및 Fine-tuning 설정

◆◆ Pre-trained 모델 다운로드

◆ `tl_strategy`를 설정하여 `param.requires_grad = False` 범위 설정

```
tl_strategy = 3

if tl_strategy == 1:
    for name, param in model.bert.named_parameters():
        print(name)
        param.requires_grad = False

elif tl_strategy == 2:
    for name, param in model.bert.named_parameters():
        if not name.startswith('pooler'):
            param.requires_grad = False

elif tl_strategy == 3:
    for name, param in model.bert.named_parameters():
        if ( not name.startswith('pooler') ) and "layer.23" not in name :
            param.requires_grad = False
```

+ 모델 학습 및 평가

◆ Training을 위한 하이퍼 파라미터 설정

◆ 모델 Output 디렉토리, Epoch 수, Batch Size 등 하이퍼 파라미터 설정

```
training_args = TrainingArguments(  
    output_dir                = model_dir,  
    num_train_epochs          = 1,  
    per_device_train_batch_size = 128,  
    per_device_eval_batch_size = 64,  
    warmup_steps              = 500,  
    weight_decay               = 0.01,  
    save_strategy              = "epoch",  
    evaluation_strategy        = "steps"  
)
```

+ 모델 학습 및 평가

◆◆ Evaluation을 위한 predict 수행

◆ trainer.predict() 함수를 이용하여 Predict 수행

```
trainer = Trainer(  
    model          = model,  
    args           = training_args,  
    compute_metrics = compute_metrics,  
)  
  
trainer.predict(test_set_dataset)
```

BERT 모델을 활용한 Text Classification 모델 구현

BERT Multi Classification 모델 구현

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 준비

◆ News 데이터 세트 업로드 및 Pandas를 이용한 데이터 로드

```
import pandas as pd

dataset = pd.read_csv("/content/mnt/MyDrive/news.csv")
```

BERT 모델을 활용한 Text Classification 모델 구현

BERT Multi Classification 모델 구현

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 준비

◆ News 데이터 세트 업로드 및 Pandas를 이용한 데이터 로드

```
dataset[dataset.category==7].head()
```

	category	num	news
1400	7	7000	호치민3쿠션월드컵 PPPQ통과 PPQ에 임정완 강상구 오성욱 등과 총 16명 출전...
1401	7	7001	한국 선수 최초로 메이저대회 시드 받는다 • 27일 프랑스오픈서 19번 내외 ...
1402	7	7002	흙 위에서 되찾은 세계 1위 클레이코트의 황제 세계랭킹 2위로 낙마한 지 1주일 만...
1403	7	7003	문체부는 빙상경기연맹에 2014년 소치 올림픽 이후 대표 선발 과정과 대표 팀 훈...
1404	7	7004	세계최강 남자 사브르 마드리드 월드컵 단체전 우승 대한민국 남자 사브르 대표팀이 월...

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 준비

◆ Label(Category)별 데이터 수

```
dataset.category.value_counts()
```

```
7    200
```

```
6    200
```

```
5    200
```

```
4    200
```

```
3    200
```

```
2    200
```

```
1    200
```

```
0    200
```

```
Name: category, dtype: int64
```

+ 학습 및 평가 데이터 세트

◆ 데이터 세트 준비

◆ Label(Category)별 데이터 수

```
train_set.shape, valid_set.shape, test_set.shape
```

```
((1024, 3), (256, 3), (320, 3))
```


+ 학습 및 평가 데이터 세트

◆ 데이터 세트 클래스 정의

◆ 데이터 세트의 Text(News)와 Label(Category)에 따라 클래스 필드명 설정

```
class BertDataset(torch.utils.data.Dataset):  
  
    def __init__(self, news, category, tokenizer):  
        self.news      = news  
        self.category   = category  
        self.tokenizer  = tokenizer  
        self.max_len    = tokenizer.model_max_length
```

BERT 모델을 활용한 Text Classification 모델 구현

BERT Multi Classification 모델 구현

+ Pre-trained 모델 다운로드 및 Fine-tuning 설정

◆◆ Pre-trained 모델 다운로드

- ◆ Huggingface로 부터 한국어 학습 모델 중 하나인 'kykim/bert-kor-base' Pre-trained 모델 다운로드
 - `num_labels = 8`은 분류할 category의 개수(class 수)

```
from transformers import BertForSequenceClassification

num_labels = 8
model = BertForSequenceClassification.from_pretrained(bert_model_name, num_labels=num_labels)
```

Downloading: 100%  1.25G/1.25G [00:35<00:00, 36.9MB/s]

+ 모델 학습 및 평가

◆ Training을 위한 하이퍼 파라미터 설정

◆ 모델 Output 디렉토리, Epoch 수, Batch Size 등 하이퍼 파라미터 설정

```
training_args = TrainingArguments(  
    output_dir                = model_dir,  
    num_train_epochs          = 1,  
    per_device_train_batch_size = 128,  
    per_device_eval_batch_size = 64,  
    warmup_steps              = 500,  
    weight_decay               = 0.01,  
    save_strategy              = "epoch",  
    evaluation_strategy         = "steps"  
)
```